Exercício Final — Análise de Dados com OpenMP

Coeficiente de variação da estatura e do peso

Aluno: Marcelo de Castro Pereira Junior · Matrícula: 2222130019

Ciência da Computação — IESB · Programação Paralela · Prof. Rodrigo Gonçalves Pinto · Novembro de 2026

1. O que o programa faz

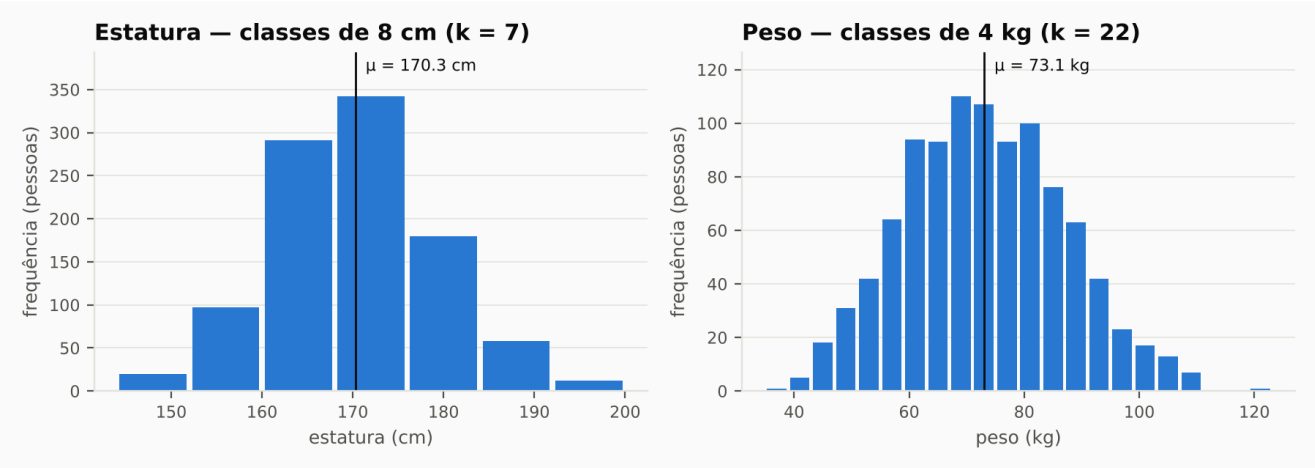
O programa, escrito em C++ (`src/cv_openmp.cpp`), lê um arquivo com a estatura e o peso de 1000 pessoas e agrupa os valores em faixas (classes): 8 cm para a estatura e 4 kg para o peso. Com essas classes, calcula a média, o desvio padrão e o **coeficiente de variação (CV)** de cada variável, usando as fórmulas do enunciado para dados agrupados. A primeira classe começa no menor valor, arredondado para baixo: na estatura, por exemplo, ela vai de 144 a 152 cm. Nos cálculos, cada classe é representada pelo seu ponto médio.

O enunciado não trouxe o arquivo de dados. Por isso, usei 1000 pessoas geradas por computador, com valores realistas (`dados/pessoas_1000.txt`). O programa aceita qualquer outro arquivo no mesmo formato.

Para medir o ganho do paralelismo, o programa tem duas versões do cálculo: uma **sequencial**, que usa um núcleo do processador, e uma **paralela**, que usa vários núcleos com OpenMP. As duas rodam sobre os mesmos dados.

2. Resultados

Variável	Média	Desvio padrão	Coeficiente de variação
Estatura	170,30 cm	9,24 cm	**5,43 %**
Peso	73,06 kg	13,99 kg	**19,16 %**



Quantidade de pessoas em cada classe. A linha vertical marca a média.

O CV mede o quanto os valores variam em relação à média. Como é dado em porcentagem, ele permite comparar variáveis com unidades diferentes, como cm e kg. A **estatura varia pouco (5,43 %)**: as pessoas têm alturas parecidas. O **peso varia bem mais (19,16 %)**, cerca de 3,5 vezes mais que a estatura. Isso é esperado, porque o peso depende da altura e também do tipo físico de cada pessoa.

As versões sequencial e paralela chegaram aos mesmos valores. Um segundo cálculo, feito à parte em Python (`scripts/verificar.py`), confirmou os resultados.

3. O que foi paralelizado e por quê

O cálculo de cada variável tem quatro passos, e todos foram paralelizados com OpenMP. Os dois primeiros passos percorrem as 1000 pessoas. Os dois últimos percorrem só as classes: 7 de estatura e 22 de peso.

Passo	O que faz	Diretiva OpenMP
1	encontra o menor e o maior valor, para montar as classes	`parallel for reduction(min:mn) reduction(max:mx)`
2	conta quantas pessoas caem em cada classe	`parallel for reduction(+ : f[:k])`
3	faz as somas da média	`parallel for reduction(+ : sxf, sf)`
4	faz a soma do desvio padrão	`parallel for reduction(+ : s)`

A diretiva `parallel for` divide as repetições de um laço entre os núcleos do processador. Mas todos os passos acumulam um resultado numa mesma variável: uma soma, um contador, um mínimo ou um máximo. Se várias threads mexessem nessa variável ao mesmo tempo, algumas atualizações se perderiam e o resultado sairia errado. Esse problema se chama **condição de corrida**.

A cláusula `reduction` resolve o problema: cada thread faz a sua parte da conta separadamente e, no final, o OpenMP junta os resultados parciais. Essa solução é mais rápida que proteger a variável a cada atualização. Com `critical`, as threads esperam a vez de usar a variável. Com `atomic`, todas disputam a mesma posição de memória.

A leitura do arquivo não foi paralelizada. Ela acontece uma única vez, antes dos cálculos, e o enunciado pede a paralelização dos laços de cálculo.

4. Comparação de desempenho

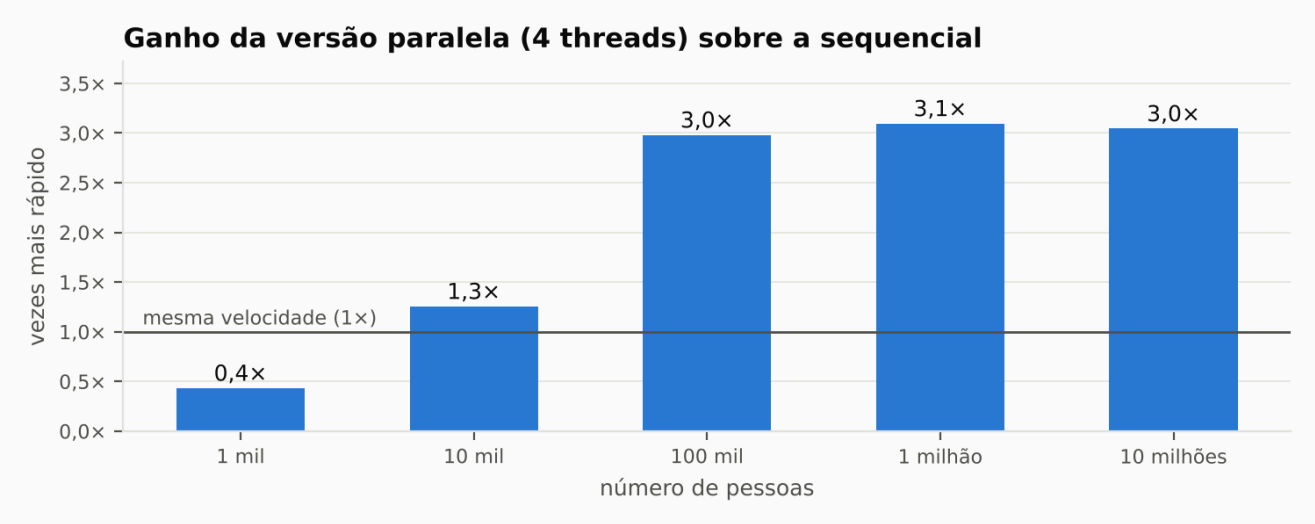
Medi as duas versões num computador com 4 núcleos. Cada medição foi repetida várias vezes (2000 vezes no caso das 1000 pessoas), e usei o tempo típico de cada versão (a mediana).

Com as 1000 pessoas do exercício, a versão paralela foi mais lenta:

	Sequencial	Paralela (4 threads)
Tempo do cálculo	5,9 µs	13,5 µs

Um µs é um milionésimo de segundo. O cálculo é tão rápido que organizar o trabalho entre as threads leva mais tempo que o próprio cálculo. Organizar o trabalho é dividir o laço, esperar todas as threads terminarem e juntar os resultados. Isso pesa ainda mais nos passos 3 e 4, que têm só de 7 a 22 repetições. Como são tempos de microssegundos, eles variam de uma execução para outra: em testes repetidos, a versão paralela levou de cerca de 13 µs a 25 µs, mas foi mais lenta que a sequencial em todas as execuções.

Para descobrir a partir de quando o paralelismo compensa, rodei o mesmo programa com mais pessoas:



Quantas vezes a versão paralela foi mais rápida que a sequencial. Abaixo da linha, ela foi mais lenta.

Pessoas	Sequencial	Paralela (4 threads)	Resultado
1 mil	0,006 ms	0,014 ms	paralela 2,3× mais lenta
10 mil	0,05 ms	0,04 ms	paralela 1,3× mais rápida
100 mil	0,54 ms	0,18 ms	paralela 3,0× mais rápida
1 milhão	5,6 ms	1,8 ms	paralela 3,1× mais rápida
10 milhões	64 ms	21 ms	paralela 3,0× mais rápida

A versão paralela passa a ganhar a partir de cerca de 10 mil pessoas. Com muitos dados, fica cerca de **3 vezes mais rápida** com 4 threads. Ela não chega a 4 vezes porque parte do tempo continua indo para coordenar as threads, e porque os núcleos dividem recursos da máquina, como o acesso à memória.

Há um limite importante. Numa execução normal, que lê o arquivo e faz o cálculo uma vez, a leitura ocupa cerca de 97 % do tempo, e ela não foi paralelizada. Por isso, mesmo com o cálculo 3 vezes mais rápido, o tempo total do programa quase não muda.

5. Conclusão

Os coeficientes de variação foram **5,43 % para a estatura** e **19,16 % para o peso**. As versões sequencial e paralela deram os mesmos resultados, e o uso de `reduction` evitou as condições de corrida.

Para as 1000 pessoas do exercício, o paralelismo não compensa, porque o cálculo é rápido demais para pagar o custo de organizar as threads. O ganho só aparece com volumes maiores de dados e chega a cerca de 3 vezes com 4 threads.

Como executar: `make` e depois `./cv_openmp dados/pessoas_1000.txt 4`. Os detalhes estão no `README.md`.